# AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad MUSTAFA DÜRÜ | Grup GECE B | Tarih

**Kavram — Prediction ≠ Safety:** Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

*Senaryo: PaketPro'ya YZ'li görsel paket kontrolü **eklenmesi planlanıyor** — proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

## Görev — üç başarısızlıkta güvenli davranış

1 **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

YZ bozuk palete OK verse bile gerginlik ve basınç sensörleri ikinci kontrolü yapmalı. Ayrıca ışık perdeleri YZ'den bağımsız olmalı ve operatör ekrandan müdahale edebilmeli

2 **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Görüntü donarsa veya giriş fotoseliyle çelişirse izleme (monitoring) ile fark edilir. Şüpheli durumda makine güvenli duruşa (fail-safe) geçip durmalı ve alarm vermeli.

3 **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Eşik (confidence threshold) en az %85 olmalı. Altına düşerse otomatik işlem durmalı, klasik sensör moduna (fallback) geçilmeli veya operatörden onay istenmeli.

## Karar tablosu — AI Fail-Safe Decision

| Başarısızlık | Tanımladığınız güvenli davranış (hangi kavramla?) |
|---|---|
| Model yanlış sınıflandırdı | Human Override: Fiziksel sensörlerle ikinci kontrol yapılır, operatöre durdurma yetkisi verilir ve Safety PLC bağımsız çalışır. |
| Girdi manipüle edildi | Monitoring & Fail-Safe: Kamera ve sensör uyumu izlenir; bozuk/sahte veride makine güvenli duruma (Safe State) geçip durur. |
| Confidence düştü | Confidence Threshold & Fallback: Güven %85'in altına düşerse makine durur ve ekrandan operatöre sorar (insan onayı). |

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.